

ST1630 — Sistemas Intensivos en Datos

# Proyecto Final

---

Enunciado, Restricciones y Rúbricas de Evaluación

Versión para estudiantes · 2026

## 1. Contexto del Proyecto

A lo largo del curso construyeron sistemas de datos con tecnologías de distinto nivel de abstracción: desde un cluster Hadoop con MapReduce (T2), pasando por Spark sobre datos estructurados (T3/T4), hasta una arquitectura Lakehouse completa con Apache Iceberg, MinIO y Trino (T5/T6). La última parte del curso introduce el eje que completa el cuadro: **mensajería de eventos (Kafka/Kinesis)**, **procesamiento en tiempo real (Flink)** y **bases de datos NoSQL** como capa de servicio operacional.

El proyecto final integra **ambos ejes** en un sistema de datos híbrido.

## 2. Enunciado del Problema

El grupo debe diseñar e implementar un **sistema de datos híbrido** para un dominio de su elección que procese información por dos caminos complementarios:

### Camino Batch

Datos históricos o de archivo procesados en bloques: ingestión → transformación → almacenamiento analítico en un Lakehouse (Bronze / Silver / Gold sobre Iceberg + MinIO).

### Camino Streaming

Eventos que llegan en tiempo real a través de un broker de mensajes (Kafka o Kinesis), se procesan con un motor de streaming (Flink) y se persisten en una base de datos NoSQL optimizada para consultas operacionales rápidas.

Ambos caminos deben servir para responder preguntas **distintas y complementarias** sobre el mismo dominio: las consultas batch responden preguntas históricas y analíticas; las consultas NoSQL responden preguntas operacionales en tiempo real.

**Dominio:** libre elección del grupo. Ejemplos con buen ajuste al modelo híbrido:

| Dominio          | Camino Batch                         | Camino Streaming                            |
|------------------|--------------------------------------|---------------------------------------------|
| E-commerce       | Historial de ventas por mes y región | Pedidos en curso, inventario en tiempo real |
| Movilidad urbana | Rutas y tiempos de viaje por semana  | Posición GPS de vehículos activos           |
| Salud / IoT      | Registros clínicos históricos        | Lecturas de sensores en tiempo real         |
| Finanzas         | Movimientos bancarios por periodo    | Alertas de transacciones sospechosas        |
| Educación        | Calificaciones y deserción histórica | Actividad de sesiones activas en plataforma |

## 3. Restricciones Técnicas

### 3.1 Obligatorias

| Componente          | Tecnología requerida            | Justificación                            |
|---------------------|---------------------------------|------------------------------------------|
| Infraestructura     | Docker Compose                  | Reproducibilidad local garantizada       |
| Mensajería          | Apache Kafka (o Kinesis en AWS) | Desacoplamiento productor/consumidor     |
| Streaming           | Apache Flink                    | Motor de streaming con estado y ventanas |
| Procesamiento batch | Apache Spark — PySpark          | Motor batch del curso                    |
| Table format        | Apache Iceberg + REST Catalog   | ACID, Time Travel, Schema Evolution      |

| Componente          | Tecnología requerida                             | Justificación                        |
|---------------------|--------------------------------------------------|--------------------------------------|
| Object storage      | MinIO (o S3 en AWS)                              | Almacenamiento del Lakehouse         |
| Base de datos NoSQL | MongoDB, Cassandra o Redis                       | Servicio de consultas operacionales  |
| Arquitectura batch  | Capas Bronze → Silver → Gold                     | Pipeline trazable e idempotente      |
| Fuentes de datos    | Mínimo 2 fuentes, 1.000+ filas/eventos           | Complejidad mínima de datos          |
| Lotes batch         | Mínimo 2 lotes de ingestión en Bronze            | Demuestra append acumulativo         |
| Features Iceberg    | Mínimo 2 de: ACID, Time Travel, Schema Evolution | Diferenciador frente a Parquet plano |

### 3.2 Opcionales — bonificación hasta +5 puntos

- Trino como tercer motor de consulta SQL sobre la capa Gold.
- Spark Structured Streaming como alternativa o complemento a Flink.
- Makefile que orqueste el pipeline completo en un solo comando.
- Jupyter Notebook de análisis exploratorio sobre la capa Gold o NoSQL.

### 3.3 Lo que NO está permitido

- Implementar solo el camino batch sin ningún componente de streaming o NoSQL.
- Usar únicamente Parquet plano (sin Iceberg) en la capa batch.
- Un productor de Kafka que genere datos triviales sin lógica de dominio (ej: contador de números aleatorios).
- Hardcodear rutas absolutas del equipo del desarrollador.

## 4. Rúbricas de Evaluación

### 4.1 Descripción del Problema y Planteamiento — 18 pts

Entrega escrita **antes de comenzar a construir**. El profesor valida que el dominio y la complejidad son adecuados.

| Criterio                                   | Excelente                                                                                                        | Aceptable                                                                    | Deficiente                                    | Pts |
|--------------------------------------------|------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------|-----------------------------------------------|-----|
| <b>1.1 Contexto y dominio (4 pts)</b>      | Dominio realista, impacto medible, complejidad justificada, diferencia clara entre preguntas batch y streaming.  | Dominio válido pero la separación batch/streaming es forzada o poco natural. | Dominio trivial o sin justificación.          | /4  |
| <b>1.2 Enunciado del problema (4 pts)</b>  | Al menos 2 preguntas analíticas (batch) y 2 operacionales (streaming) claramente formuladas.                     | Preguntas definidas pero solo de un tipo o poco precisas.                    | No se definen preguntas de negocio concretas. | /4  |
| <b>1.3 Fuentes y esquemas (5 pts)</b>      | Dos fuentes descritas con esquema, volumen y frecuencia; se distingue dato histórico de evento.                  | Fuentes descritas sin esquema o sin diferenciar tipos de dato.               | Solo menciona que habrá datos.                | /5  |
| <b>1.4 Justificación del stack (5 pts)</b> | Cada componente ligado a una necesidad del dominio (ej: 'Cassandra porque necesitamos queries por time series'). | Menciona las tecnologías pero sin relación directa con el problema.          | Lista herramientas sin justificación.         | /5  |

### 4.2 Arquitectura e Infraestructura — 12 pts

| Criterio                                    | Excelente                                                                                                                   | Aceptable                                                                | Deficiente                                   | Pts |
|---------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------|----------------------------------------------|-----|
| <b>2.1 Docker Compose (5 pts)</b>           | Levanta sin errores con 'docker compose up'; todos los servicios healthy (Kafka, Flink, Spark, MinIO, NoSQL, REST Catalog). | Levanta con ajustes manuales menores.                                    | No levanta o faltan servicios clave.         | /5  |
| <b>2.2 Diagrama de arquitectura (4 pts)</b> | Ambos caminos claramente diferenciados, componentes etiquetados, tecnología de cada nodo visible.                           | Diagrama presente pero solo cubre uno de los dos caminos.                | No hay diagrama o es ilegible.               | /4  |
| <b>2.3 Reproducibilidad (3 pts)</b>         | README con comandos exactos para levantar y correr el pipeline completo sin pasos manuales.                                 | Ejecutable con README detallado pero con pasos manuales no documentados. | Requiere intervención verbal no documentada. | /3  |

### 4.3 Capa de Mensajería — Kafka / Kinesis — 12 pts

| Criterio                                | Excelente                                                                                                 | Aceptable                                         | Deficiente                                                       | Pts |
|-----------------------------------------|-----------------------------------------------------------------------------------------------------------|---------------------------------------------------|------------------------------------------------------------------|-----|
| <b>3.1 Productor de eventos (5 pts)</b> | Productor en Python/Java que publica eventos con esquema JSON claro, a un ritmo coherente con el dominio. | Productor funcional con datos sintéticos simples. | Datos hardcoded sin un productor real.                           | /5  |
| <b>3.2 Config de tópicos (4 pts)</b>    | Tópico con al menos 2 particiones, retención configurada, offsets visibles.                               | Tópico creado con configuración por defecto.      | No se configuran tópicos o una sola partición sin justificación. | /4  |

| Criterio                   | Excelente                                                               | Aceptable                                        | Deficiente                                         | Pts |
|----------------------------|-------------------------------------------------------------------------|--------------------------------------------------|----------------------------------------------------|-----|
| 3.3 Observabilidad (3 pts) | Se puede ver el lag del consumer o los mensajes en la consola de Kafka. | Logs del productor presentes pero no del broker. | No hay forma de verificar que los mensajes fluyen. | /3  |

#### 4.4 Procesamiento en Streaming — Apache Flink — 15 pts

| Criterio                                | Excelente                                                                                           | Aceptable                                                    | Deficiente                                | Pts |
|-----------------------------------------|-----------------------------------------------------------------------------------------------------|--------------------------------------------------------------|-------------------------------------------|-----|
| 4.1 Consumo de Kafka (4 pts)            | Job Flink conectado al tópico, deserialización de JSON funcional, offsets comprometidos.            | Job conecta pero falla con ciertos mensajes.                 | No consume de Kafka o usa polling manual. | /4  |
| 4.2 Transformaciones con estado (5 pts) | Usa al menos un tipo de ventana (tumbling, sliding o session) para agregar eventos por tiempo.      | Transforma eventos sin estado (solo map/filter).             | Pasa los eventos sin transformar.         | /5  |
| 4.3 Sink hacia NoSQL (4 pts)            | Resultados del stream persistidos correctamente en MongoDB/Cassandra/Redis con el esquema definido. | Escribe al NoSQL pero el esquema es incorrecto o incompleto. | No escribe al NoSQL desde Flink.          | /4  |
| 4.4 Semántica de entrega (2 pts)        | Job configura checkpointing y menciona la semántica usada (at-least-once / exactly-once).           | Checkpointing configurado sin justificación.                 | No se configura manejo de fallas.         | /2  |

#### 4.5 Base de Datos NoSQL — 12 pts

| Criterio                             | Excelente                                                                                                          | Aceptable                                                                 | Deficiente                                             | Pts |
|--------------------------------------|--------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------|--------------------------------------------------------|-----|
| 5.1 Justificación del modelo (4 pts) | El esquema NoSQL está diseñado para las consultas operacionales (ej: row-key por timestamp en Cassandra para IoT). | Modelo funcional pero genérico, no optimizado para las queries definidas. | Colección / tabla sin diseño pensado para el dominio.  | /4  |
| 5.2 Consultas operacionales (5 pts)  | 3+ queries que responden las preguntas operacionales del enunciado, resultados correctos.                          | 2 queries o resultados parcialmente correctos.                            | Menos de 2 queries o sin conexión al dominio.          | /5  |
| 5.3 Diferencia con SQL (3 pts)       | Argumenta ventajas concretas: escalabilidad horizontal, esquema flexible, acceso por clave primaria vs scan.       | Da una respuesta general pero no contextualizada al problema.             | No puede justificar la elección de NoSQL frente a SQL. | /3  |

#### 4.6 Pipeline Batch — Spark + Lakehouse Iceberg — 15 pts

| Criterio                | Excelente                                                                                                           | Aceptable                                                                  | Deficiente                                     | Pts |
|-------------------------|---------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------|------------------------------------------------|-----|
| 6.1 Capa Bronze (4 pts) | Dos lotes de append, metadatos de auditoría (timestamp de ingestión, origen del archivo), sin pérdida de historial. | Un lote funcional o append sin metadatos de trazabilidad.                  | Solo createOrReplace (sin historial de lotes). | /4  |
| 6.2 Capa Silver (5 pts) | Maneja nulos y tipos incorrectos, hace JOIN con al menos una dimensión, columnas calculadas.                        | Limpieza básica sin join o sin validaciones.                               | Copia datos de Bronze sin transformar.         | /5  |
| 6.3 Capa Gold (3 pts)   | Agregaciones sobre dimensiones clave, tablas que responden las preguntas batch del enunciado.                       | Agregaciones simples correctas pero sin responder las preguntas definidas. | No existe Gold o es idéntico a Silver.         | /3  |

| Criterio                            | Excelente                                                                                       | Aceptable                             | Deficiente                | Pts |
|-------------------------------------|-------------------------------------------------------------------------------------------------|---------------------------------------|---------------------------|-----|
| <b>6.4 Features Iceberg (3 pts)</b> | Los 3 features demostrados (ACID, Time Travel, Schema Evolution) con verificación del snapshot. | 2 features demostrados correctamente. | Solo 1 feature o ninguno. | /3  |

#### 4.7 Integración y Consultas Analíticas — 10 pts

| Criterio                                    | Excelente                                                                                                                                           | Aceptable                                                   | Deficiente                                    | Pts |
|---------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------|-----------------------------------------------|-----|
| <b>7.1 Coherencia entre caminos (4 pts)</b> | El grupo muestra una pregunta que cruza datos batch (histórico) con datos streaming (tiempo real), o explica con claridad qué responde cada camino. | Los dos caminos funcionan pero son independientes entre sí. | Los dos caminos no tienen relación entre sí.  | /4  |
| <b>7.2 Queries sobre Gold (4 pts)</b>       | 5+ queries Spark SQL con su pregunta de negocio y la interpretación del resultado en lenguaje del dominio.                                          | 3-4 queries o sin interpretación de resultados.             | Menos de 3 queries o resultados sin contexto. | /4  |
| <b>7.3 Comparación de capas (2 pts)</b>     | Explica cuándo consultar NoSQL (operacional / baja latencia) vs Gold/Trino (analítico / alta cardinalidad).                                         | Da una respuesta general no contextualizada.                | No puede diferenciar los casos de uso.        | /2  |

#### 4.8 Calidad del Código y Documentación — 5 pts

| Criterio                         | Excelente                                                                                                  | Aceptable                                                      | Deficiente                                           | Pts |
|----------------------------------|------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------|------------------------------------------------------|-----|
| <b>8.1 README (2 pts)</b>        | Prerequisites, comandos exactos por componente, descripción de cada capa y tópico, capturas de UIs clave.  | README presente pero incompleto.                               | Sin README o ilegible.                               | /2  |
| <b>8.2 Código limpio (3 pts)</b> | Configuración en variables de entorno o .env, scripts separados por capa/componente, sin código comentado. | Algunos hardcodes menores, estructura razonablemente separada. | Paths absolutos, scripts monolíticos, código muerto. | /3  |

#### 4.9 Presentación y Demo en Vivo — 8 pts

| Criterio                           | Excelente                                                                                                              | Aceptable                                               | Deficiente                                     | Pts |
|------------------------------------|------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------|------------------------------------------------|-----|
| <b>9.1 Demo funcional (4 pts)</b>  | Ambos caminos (batch y streaming) corren sin intervención manual, resultados visibles en NoSQL y en Gold.              | Un camino funciona completamente, el otro parcialmente. | Ningún camino funciona en la presentación.     | /4  |
| <b>9.2 Defensa técnica (4 pts)</b> | Justifican cada elección tecnológica y pueden describir qué pasaría si cambia un requisito (ej: eventos desordenados). | Responden la mayoría de preguntas con apoyo del código. | No pueden justificar sus decisiones de diseño. | /4  |

## 5. Resumen de Pesos

| Sección | Descripción                                | Puntos     | %            |
|---------|--------------------------------------------|------------|--------------|
| 4.1     | Descripción del problema y planteamiento   | 18         | 18 %         |
| 4.2     | Arquitectura e infraestructura             | 12         | 12 %         |
| 4.3     | Capa de mensajería — Kafka / Kinesis       | 12         | 12 %         |
| 4.4     | Procesamiento en streaming — Flink         | 15         | 15 %         |
| 4.5     | Base de datos NoSQL                        | 12         | 12 %         |
| 4.6     | Pipeline batch — Spark + Lakehouse Iceberg | 15         | 15 %         |
| 4.7     | Integración y consultas analíticas         | 10         | 10 %         |
| 4.8     | Calidad del código y documentación         | 5          | 5 %          |
| 4.9     | Presentación y demo en vivo                | 8          | 8 %          |
|         | <b>TOTAL</b>                               | <b>100</b> | <b>100 %</b> |

**Bonificación** — hasta +5 puntos adicionales sobre 100:

| Componente                        | Descripción                                                          | Bonus |
|-----------------------------------|----------------------------------------------------------------------|-------|
| <b>Trino</b>                      | Motor SQL adicional sobre la capa Gold (queries demostrables en CLI) | +2    |
| <b>Makefile orquestado</b>        | Un solo comando ejecuta Bronze → Silver → Gold → Flink job completo  | +1    |
| <b>Spark Structured Streaming</b> | Alternativa o complemento a Flink con micro-batches                  | +1    |
| <b>Jupyter Notebook</b>           | Análisis exploratorio sobre Gold o NoSQL con visualizaciones         | +1    |